

Informe Final — Proyecto Integrador

Análisis de usuarios de una plataforma de streaming | Minería de Datos 1
Integrantes: Vega Orellana, Ignacio Rodolfo | Romano Arnoux, Bruno Leonel

1. CONTEXTO Y OBJETIVO

Este proyecto construye un pipeline de análisis reproducible sobre un dataset de usuarios de una plataforma de streaming. El objetivo es aplicar los contenidos de Minería de Datos 1 para desarrollar un proyecto de análisis con decisiones justificadas, trazabilidad del proceso y comunicación clara de los resultados. El alcance incluye inspección inicial, limpieza, EDA, escalamiento y PCA; no es un proyecto de modelado predictivo.

2. DATASET Y CALIDAD INICIAL

El dataset original contenía **8.160 registros** y **8 variables**: `user_id`, `age`, `subscription_plan`, `monthly_watch_time_mins`, `country`, `favorite_genre`, `last_login_date` y `customer_support_tickets`. La inspección inicial identificó:

- Valores nulos en tres columnas: `monthly_watch_time_mins` (193), `favorite_genre` (240) y `last_login_date` (320).
- Tipo de dato incorrecto en `last_login_date` (cargada como object en lugar de fecha).
- Registros duplicados por `user_id` (160 duplicados detectados).
- Valores imposibles en `age` (fuera del rango 4–95) y en `monthly_watch_time_mins` (fuera del rango 0–5.000 minutos).
- Variantes inconsistentes en categorías: Estándar / ESTANDAR / Std; Brasil / Brazil / BRA; Acción / ACCIÓN / Action.
- Tres formatos de fecha mezclados en `last_login_date` (YYYY-MM-DD, MM-DD-YYYY, YYYY/MM/DD).

3. DECISIONES DE LIMPIEZA Y PREPARACIÓN

Variables categóricas

Se unificaron las variantes inconsistentes en `subscription_plan`, `country` y `favorite_genre` bajo una forma canónica (Básico/Estándar/Premium; nombres de país en minúscula; géneros capitalizados). Los nulos en `favorite_genre`, donde no era posible determinar si el dato era no registrado o una preferencia indefinida, se etiquetaron explícitamente como 'Sin Género Favorito' en lugar de imputar o eliminar el registro.

Fechas (`last_login_date`) y duplicados

Se estandarizaron los tres formatos de fecha detectados y se eliminaron los registros con fechas inválidas o irrecuperables. Se aplicó además una deduplicación por `user_id` (`keep='first'`), eliminando 160 registros duplicados.

Minutos de visualización (`monthly_watch_time_mins`)

Se filtraron los registros al rango 0–5.000 minutos mensuales, eliminando valores negativos y extremos considerados imposibles en el contexto de uso real de la plataforma.

Edad (`age`)

Se conservaron únicamente los registros con edad entre 4 y 95 años, eliminando valores imposibles para usuarios reales (edades negativas, cero o superiores a 95 años).

El dataset original se preservó intacto en `data/raw/`. Cada transformación quedó registrada en `logs/pipeline_log.csv`, permitiendo trazar el impacto de cada paso sobre el volumen de filas y nulos.

Paso	Descripción	Filas	Nulos
01	Dataset original cargado	8.160	753
02	Eliminación de duplicados por user_id	8.000	753
03	Estandarización y limpieza de fechas	7.601	418
04	Filtrado de minutos de visualización (0–5.000 min)	7.342	227
05	Reemplazo de nulos e imputación en favorite_genre	7.342	0
06	Filtrado de edades (4–95 años)	7.251	0
07	Estandarización de países	7.251	0
08	Estandarización de subscription_plan	7.251	0

Etapa final: **7.251 filas · 8 variables · 0 nulos**. Registros eliminados respecto al original: 909 (11,1%). Dataset original preservado en data/raw/; log completo en logs/pipeline_log.csv.

4. HALLAZGOS DEL ANÁLISIS EXPLORATORIO

Distribución de edad

La base de usuarios es predominantemente adulta joven, con una edad promedio de 33,6 años y una mediana de 33 años. La mayor concentración se encuentra entre los 26 y 45 años (58,8% de la base), con muy pocos usuarios mayores de 60 años (1,2%).

Plan de suscripción predominante

El plan Básico es el más frecuente, representando el 45,9% de la base, seguido por Estándar (35,7%) y Premium (18,4%). Este segmento es el punto de referencia natural para comparaciones entre planes.

Consumo según plan

El consumo mensual de minutos crece de forma consistente de Básico (mediana 556 min) a Estándar (mediana 838 min) y de Estándar a Premium (mediana 1.127 min). Los usuarios Premium presentan un consumo claramente superior, lo que sugiere que el plan contratado se refleja en el uso real de la plataforma.

Relación entre edad y minutos visualizados

La correlación de Pearson entre age y monthly_watch_time_mins es de **0,006**, prácticamente nula. El promedio de minutos visualizados por grupo etario se mantiene estable en todos los rangos (entre 776 y 809 minutos), sin una tendencia clara de crecimiento con la edad. La hipótesis de que los usuarios de mayor edad consumen más contenido no encuentra respaldo en los datos.

Preferencia de género por país

El favorite_genre se distribuye de forma relativamente pareja entre los siete géneros estandarizados (entre 974 y 1.046 usuarios cada uno, aproximadamente 13–14% del total), y esta distribución se mantiene similar entre países: no se observa una preferencia marcadamente dominante en ningún mercado. Los géneros más elegidos por país son Comedia y Thriller en Brasil y Colombia, Drama y Romance en Uruguay y Perú, Crimen y Acción en Chile, Drama y Comedia en Argentina, y Acción y Comedia en México, aunque las diferencias entre el primer y segundo género de cada país son moderadas.

Tickets de soporte

La variable customer_support_tickets no fue depurada en el pipeline actual: conserva 24 registros con valores negativos y 63 registros con valores superiores a 20 tickets (máximo 150), lo cual es estadísticamente atípico para un período mensual. Esto se documenta como observación pendiente para una futura iteración de limpieza.

5. REDUCCIÓN DE DIMENSIONALIDAD — PCA

Se seleccionaron las tres variables numéricas del dataset: `age`, `monthly_watch_time_mins` y `customer_support_tickets`. Se aplicó `StandardScaler` antes del PCA para igualar la escala de todas las variables y evitar que `monthly_watch_time_mins` (valores que superan los 4.000 minutos) dominara el análisis sobre `customer_support_tickets` (valores que rara vez superan 5 en un caso típico).

Componente	Varianza explicada	Varianza acumulada
PC1	33,7 %	33,7 %
PC2	33,4 %	67,1 %
PC3	32,9 %	100,0 %

Las tres componentes explican proporciones casi idénticas de varianza, sin ningún codo visible en el scree plot y con crecimiento prácticamente lineal de la varianza acumulada. Esto confirma que las tres variables no están correlacionadas entre sí, por lo que PCA no permite una reducción de dimensionalidad sin pérdida significativa: retener 2 componentes implicaría conservar solo el 67,1% de la información original.

PC1 — Calidad de Experiencia (33,7%)

`monthly_watch_time_mins`: +0,74 (contribución fuerte, positiva) · `customer_support_tickets`: -0,62 (contribución fuerte, negativa) · `age`: +0,26 (contribución baja, positiva). Los usuarios con valores altos en PC1 ven más minutos, tienen mayor edad y reportan menos problemas de soporte.

PC2 — Perfil Etario (33,4%)

`age`: +0,86 (contribución muy fuerte, positiva) · `customer_support_tickets`: +0,50 (contribución media, positiva) · `monthly_watch_time_mins`: +0,12 (contribución baja, positiva). Los usuarios con valores altos en PC2 son personas mayores que además tienden a reportar más tickets de soporte.

El resultado más relevante del PCA no es la reducción en sí, sino la confirmación de que la edad, el consumo y los problemas técnicos son dimensiones independientes del comportamiento del usuario, por lo que resulta más apropiado trabajar con las variables originales en futuros análisis.

6. CONCLUSIONES Y LIMITACIONES

El análisis describió una base de usuarios predominantemente adulta joven, con el plan Básico como segmento dominante (45,9%). Se verificó que el plan contratado se refleja en el consumo real de la plataforma, con un crecimiento consistente de minutos vistos de Básico a Premium. No se encontró asociación entre la edad y el tiempo de visualización, ni una preferencia de género claramente diferenciada entre los siete países analizados. Las tres variables numéricas del dataset describen aspectos independientes del comportamiento del usuario, sin redundancia entre sí.

Limitaciones:

- El dataset no incluye información sobre el contenido efectivamente consumido, por lo que no es posible contrastar la preferencia declarada en `favorite_genre` con el consumo real.
- La variable `favorite_genre` conserva una categoría residual sin estandarizar ('Doc', 15 registros) que no fue mapeada a ninguno de los ocho géneros canónicos.
- La variable `customer_support_tickets` no fue depurada: conserva valores negativos y outliers extremos (hasta 150 tickets) que podrían distorsionar análisis futuros que la incluyan.
- La ausencia de una variable temporal de fecha de registro impide analizar la evolución del comportamiento a lo largo del tiempo (corte transversal).

- Las correlaciones prácticamente nulas entre las variables numéricas limitan la capacidad de PCA para resumir el dataset de forma compacta.

7. ENLACES

Repositorio GitHub: https://github.com/IgnaOV/PI_Mineria_Datos_1

Aplicación Streamlit: <https://pimineriadedatos01.streamlit.app>

Log ETL: logs/pipeline_log.csv | Notebooks: notebooks/ | Informe: reports/informe_final.pdf